

**Identificación y modelización de una firma
transcriptómica asociada a metástasis ganglionar
mediante análisis pseudobulk de datos single-cell
RNA-seq**

Trabajo Fin de Máster
Máster en Bioinformática y Bioestadística
2026

Francisco Manuel González Nuño

Tutora: Izaskun Mallona

Análisis de datos ómicos

Índice de Contenidos

1	Tabla resumen	2
2	Contexto y justificación del trabajo	2
3	Descripción general	3
4	Objetivos del proyecto	4
4.1	Objetivo general	4
4.2	Objetivos específicos	4
4.3	Objetivos secundarios/opcionales/exploratorios	4
5	Enfoque y método a seguir	5
5.1	Estrategias posibles consideradas	5
5.2	Estrategia elegida	5
6	Impacto en sostenibilidad, ético-social y de diversidad	6
7	Planificación	6
7.1	Tareas	6
7.2	Calendario	8
7.3	Hitos	9
7.4	Análisis de riesgos	9
8	Resultados esperados	9
9	Bibliografía	10

List of Tables

1	Calendario y distribución de tareas.	8
2	Tabla de análisis de riesgos	11

List of Figures

1	Diagrama de Gantt: calendario y distribución temporal de tareas. El color naranja es indicativo de tarea; el color azul, de subtarea; el verde, de tarea transversal; y el rojo, de hito final. El número en el color indica la duración estimada en días.	8
---	--	---

1 Tabla resumen

Título	provi-	Identificación y modelización de una firma transcriptómica asociada a metástasis ganglionar mediante análisis pseudobulk de datos single-cell RNA-seq.
Palabras clave		scRNA-seq; tumor heterogeneity; colorectal cancer; transcriptomics; pseudobulk analysis; machine learning; artificial intelligence

2 Contexto y justificación del trabajo

El cáncer colorrectal (CRC) constituye uno de los tumores con mayor incidencia y mortalidad a nivel mundial. Según el informe GLOBOCAN¹2020, el CRC representa el tercer cáncer más diagnosticado y la segunda causa de muerte por cáncer a nivel global [[1]]. A pesar de los avances terapéuticos, la progresión metastásica continúa siendo el principal determinante del pronóstico.

Un elemento clave en la progresión tumoral es la heterogeneidad intratumoral, entendida como la coexistencia de subpoblaciones celulares molecularmente distintas dentro de un mismo tumor. Esta heterogeneidad influye en la evolución clonal, la adaptación al microambiente y la resistencia a tratamientos [[2]].

Las aproximaciones transcriptómicas bulk tradicionales proporcionan una señal promedio de la muestra, lo que dificulta la detección de subclones minoritarios o estados celulares transitorios. La aparición de la transcriptómica de célula única (single-cell RNA sequencing, scRNA-seq) ha permitido superar esta limitación, ofreciendo una resolución sin precedentes en la caracterización de la variabilidad celular [[3], [4]].

El conjunto de datos público *GSE97693*, publicado en *Science* [[5]], constituye un recurso relevante para estudiar la heterogeneidad tumoral en cáncer colorrectal mediante *scTrio-seq2*, técnica que permite analizar simultáneamente transcriptómica y metilación a nivel de célula individual. Este tipo de datos proporciona un escenario idóneo para aplicar técnicas computacionales avanzadas.

El análisis de datos de célula única presenta retos metodológicos específicos, tales como la alta dimensionalidad, la dispersión de los datos, el ruido técnico y la variabilidad interpaciente. En este escenario, las técnicas de inteligencia artificial, como el aprendizaje automático (*machine learning*), se han consolidado como herramientas esenciales para la reducción de dimensionalidad, la integración de datos y la eliminación de efectos de lote (*batch effect*), permitiendo una caracterización robusta de los estados celulares [[6]].

El presente trabajo se justifica mediante distintos aspectos clave. En primer lugar, la importancia clínica y epidemiológica del cáncer colorrectal, que continúa siendo uno de los principales retos en salud pública. En segundo lugar, la necesidad de disponer de metodologías avanzadas capaces de caracterizar la heterogeneidad tumoral, un fenómeno central en la progresión del cáncer y en la respuesta terapéutica. Asimismo, este trabajo aprovecha la oportunidad de aplicar técnicas de

¹<https://gco.iarc.fr/en>

machine learning a datos reales de *single-cell*, un ámbito en rápida expansión que permite explorar la complejidad celular con una resolución sin precedentes.

En conjunto, este trabajo aborda un problema biomédico de relevancia mediante herramientas computacionales avanzadas y un enfoque metodológico riguroso.

3 Descripción general

Este Trabajo Fin de Máster se centrará en el estudio de la heterogeneidad transcriptómica del cáncer colorrectal a resolución de célula individual, con especial énfasis en la identificación de programas moleculares asociados a la progresión metastásica. A partir de datos de secuenciación de ARN de célula única procedentes de tumor primario, metástasis ganglionar y tejido normal adyacente, el proyecto abordará el análisis integrado de la arquitectura celular tumoral y los cambios transcriptómicos vinculados a la diseminación tumoral.

El eje central del trabajo será la exploración y caracterización de una posible firma transcriptómica asociada a la progresión metastásica, entendida como un conjunto coherente de genes cuya expresión distingue las células tumorales del tumor primario de aquellas presentes en metástasis ganglionar. La firma se analizará integrada en la arquitectura celular del tumor, atendiendo tanto a la variedad de estados celulares presentes como a la contribución relativa de los distintos tipos celulares al fenotipo metastásico.

El trabajo se estructurará en varias fases. En primer lugar, se realizará un análisis exploratorio y reducción de dimensionalidad mediante técnicas como PCA o UMAP. Seguidamente, se analizarán las posibles subpoblaciones celulares que serán anotadas mediante métodos automáticos de referencia.

En una segunda fase, el análisis se centrará en comparar las células de las distintas regiones (tejido normal, tumor primario y metástasis ganglionar) con el fin de identificar diferencias transcriptómicas asociadas a la progresión tumoral. Se emplearán enfoques de análisis diferencial junto con técnicas de análisis y modelos de aprendizaje automático para identificar los genes con mayor capacidad discriminativa entre ambas localizaciones.

Finalmente, se evaluará de manera exploratoria la asociación entre la activación de la firma metastásica, la composición celular tumoral y variables clínicas como el estadio AJCC, con el fin de explorar posibles relaciones entre heterogeneidad transcriptómica y progresión clínica.

En conjunto, el proyecto combinará análisis de heterogeneidad celular, estadística inferencial y técnicas de aprendizaje automático interpretables para caracterizar los programas moleculares asociados a la metástasis en cáncer colorrectal, integrando información biológica y clínica dentro de un marco metodológico coherente.

4 Objetivos del proyecto

4.1 Objetivo general

Identificar y caracterizar una posible firma transcriptómica asociada al desarrollo tumoral en cáncer colorrectal mediante el análisis de datos de secuenciación de ARN a nivel de célula individual, integrando el estudio de la heterogeneidad celular tumoral, la modelización computacional y el contexto clínico disponible.

4.2 Objetivos específicos

1. Reconstruir la arquitectura celular del cáncer colorrectal a resolución single-cell, identificando subpoblaciones y estados celulares relevantes, con especial atención al compartimento epitelial tumoral.
2. Identificar un potencial conjunto de genes diferencialmente expresados entre células de tumor primario y metástasis ganglionar.
3. Evaluar la capacidad discriminativa de la firma metastásica mediante modelos supervisados de aprendizaje automático interpretables, identificando posibles variables génicas con mayor contribución al modelo discriminante.
4. Analizar la relevancia funcional y biológica de los genes identificados asociados a la metástasis mediante análisis de enriquecimiento y contextualización en procesos implicados en progresión tumoral.
5. Realizar un análisis integrado de actividad de vías y reguladores en scRNA-seq.
6. Implementar el análisis en un entorno computacional estructurado que garantice la trazabilidad y reproducibilidad de los resultados.

4.3 Objetivos secundarios complementarios

1. Comparar de manera exploratoria la activación de la firma metastásica con el tejido normal adyacente, evaluando posibles gradientes transcriptómicos entre tejido normal, tumor primario y metástasis ganglionar.
2. Analizar posibles diferencias en la composición celular entre tumor primario y metástasis ganglionar y su contribución al fenotipo metastásico.
3. Explorar la asociación entre la intensidad de activación de la firma metastásica y variables clínicas disponibles, como el estadio tumoral (AJCC).
4. Evaluar la robustez de la firma identificada mediante estrategias adicionales de validación interna (por ejemplo, esquemas de validación leave-one-out).

5 Enfoque y método a seguir

El estudio de la progresión metastásica en cáncer colorrectal a partir de datos transcriptómicos puede abordarse mediante distintas estrategias analíticas, que difieren tanto en el nivel de resolución considerado como en el marco estadístico empleado.

5.1 Estrategias posibles consideradas

Una primera estrategia consistiría en realizar un análisis transcriptómico convencional a nivel de muestra agregada, utilizando perfiles promedio o pseudobulk sin considerar explícitamente la heterogeneidad celular. Este enfoque simplifica la dimensionalidad del problema y permite aplicar metodologías estadísticas bien establecidas, pero pierde la resolución celular que caracteriza a los datos single-cell y puede enmascarar estados celulares minoritarios relevantes para la progresión metastásica.

Una segunda estrategia sería plantear el análisis exclusivamente a nivel celular, comparando directamente células individuales del tumor primario y de la metástasis ganglionar. Este enfoque explota plenamente la resolución single-cell, pero introduce dependencias estadísticas entre células del mismo paciente y puede sobreestimar la potencia si no se controla adecuadamente la variabilidad interpaciente.

Una tercera estrategia, más integradora, combina ambos niveles: utiliza el análisis single-cell para reconstruir la arquitectura celular y definir subpoblaciones relevantes, y posteriormente aplica estrategias de agregación controlada (pseudobulk por paciente y tejido) para realizar comparaciones diferenciales y desarrollar modelos supervisados minimizando la dependencia entre observaciones.

5.2 Estrategia elegida

En este trabajo se optará por una estrategia integradora que permitirá explotar la riqueza informativa de los datos single-cell sin ignorar la estructura jerárquica del diseño experimental.

Justificación: La estrategia seleccionada se considera la más adecuada por varias razones. En primer lugar, permite preservar la resolución celular necesaria para estudiar la heterogeneidad tumoral, elemento central del proyecto. En segundo lugar, el uso de agregación por paciente reduce el riesgo de pseudorreplicación y mejora la validez estadística de las comparaciones entre tumor primario y metástasis ganglionar. En tercer lugar, la incorporación de modelos supervisados interpretables facilita la identificación de genes con capacidad discriminativa real, más allá de diferencias estadísticas aisladas.

Asimismo, este enfoque permite integrar análisis exploratorios adicionales, como la comparación con tejido normal o la asociación con variables clínicas, sin comprometer la coherencia del núcleo metodológico.

En conjunto, la estrategia adoptada equilibra resolución biológica, rigor estadístico e interpretabilidad computacional, alineándose de forma directa con los objetivos planteados en el proyecto.

6 Impacto en sostenibilidad, ético-social y de diversidad

El proyecto impacta principalmente en la categoría *ODS 3 - Salud y bienestar*, promovido por Naciones Unidas², al contribuir al avance en la comprensión molecular de la progresión metastásica en cáncer colorrectal, una de las principales causas de mortalidad oncológica a nivel global.

Desde una perspectiva ético-social, el trabajo se fundamenta exclusivamente en el análisis de datos públicos previamente anonimizados y con aprobación ética, sin implicar intervención directa sobre pacientes. Esto garantiza el respeto a los principios de confidencialidad, no maleficencia y uso responsable de la información biomédica.

Asimismo, el conjunto de datos utilizado incluye muestras procedentes tanto de hombres como de mujeres, permitiendo un análisis que contempla la diversidad biológica y evita sesgos derivados de estudios centrados en un único sexo.

Desde el punto de vista de sostenibilidad ecológica, el proyecto presenta un impacto ambiental reducido al basarse exclusivamente en datos ya generados, evitando el consumo de reactivos o recursos experimentales.

7 Planificación

7.1 Tareas

1. Preparación e integración de los datos.

Recopilación y organización de archivos TPM individuales.

Construcción de la matriz de expresión consolidada.

Integración de metadatos (paciente, tejido, estadio, localización anatómica).

Verificación de correspondencia entre expresión y metadatos.

Exploración inicial de dimensiones y estructura del dataset.

2. Caracterización de la arquitectura celular.

Reducción de dimensionalidad (PCA).

Construcción de representación no lineal (UMAP).

Clustering no supervisado.

Identificación de marcadores por cluster.

Anotación celular mediante métodos automáticos y marcadores conocidos.

²<https://www.un.org/sustainabledevelopment/es/sustainable-development-goals/>

- Evaluación de estabilidad del clustering.
- 3. Análisis composicional.
 - Cálculo de proporciones celulares por paciente y tejido.
 - Comparación exploratoria entre tumor primario y metástasis.
 - Visualización de cambios composicionales.
- 4. Identificación de la firma metastásica.
 - Selección de células epiteliales tumorales.
 - Generación de perfiles pseudobulk por paciente y localización.
 - Análisis diferencial PT vs LN.
 - Control de variabilidad interpaciente.
 - Identificación preliminar de genes candidatos.
- 5. Modelización.
 - Selección de variables candidatas.
 - División de datos para validación.
 - Entrenamiento de modelos supervisados.
 - Evaluación del rendimiento.
 - Extracción de importancia de variables.
 - Evaluación de estabilidad del modelo.
- 6. Construcción de una puntuación metastásica.
 - Definición del método de agregación de la firma.
 - Cálculo del puntaje por célula.
 - Agregación por paciente.
 - Visualización de gradientes (normal, tumor primario, metástasis ganglionar).
- 7. Análisis funcional y de actividad de vías y reguladores.
 - Preparación de listas génicas.
 - Análisis de enriquecimiento (GO, KEGG, Reactome).
 - Análisis de actividad de vías y reguladores.
 - Interpretación biológica de resultados.
 - Integración con literatura científica.
- 8. Análisis exploratorios adicionales.
 - Comparación con tejido normal.
 - Asociación exploratoria con estadio clínico.
 - Análisis de robustez adicional.
- 9. Redacción de la memoria final.

7.2 Calendario

La planificación de tareas y subtareas se ha realizado reflejando aquellas identificadas como principales, cuya duración queda recogida en la tabla 1 y representada gráficamente en la figura 1.

Tabla 1: Calendario y distribución de tareas.

Nombre	Nivel	Inicio	Fin	Duración
Preparación e integración de datos	TAREA	04-mar	09-mar	5
Arquitectura celular	TAREA	09-mar	24-mar	15
Reducción dimensional	SUBTAREA	09-mar	14-mar	5
Clustering	SUBTAREA	14-mar	19-mar	5
Anotación celular	SUBTAREA	19-mar	24-mar	5
Análisis composicional	TAREA	24-mar	27-mar	3
Identificación firma metastásica	TAREA	27-mar	18-abr	22
Filtrado epitelial	SUBTAREA	27-mar	30-mar	3
Generación pseudobulk	SUBTAREA	30-mar	04-abr	5
Análisis diferencial PT vs LN	SUBTAREA	04-abr	11-abr	7
Refinamiento firma	SUBTAREA	11-abr	18-abr	7
Modelización supervisada	TAREA	18-abr	03-may	15
Selección variables	SUBTAREA	18-abr	21-abr	3
Entrenamiento ML	SUBTAREA	21-abr	28-abr	7
Validación modelo	SUBTAREA	28-abr	03-may	5
Construcción metastatic score	TAREA	03-may	08-may	5
Análisis funcional	TAREA	08-may	13-may	5
Análisis exploratorios	TAREA	13-may	19-may	6
Redacción e integración final	TAREA	05-mar	03-jun	90
Documento finalizado	HITO	02-jun	03-jun	1




Figura 1: Diagrama de Gantt: calendario y distribución temporal de tareas. El color naranja es indicativo de tarea; el color azul, de subtarea; el verde, de tarea transversal; y el rojo, de hito final. El número en el color indica la duración estimada en días.

7.3 Hitos

1. Matriz de expresión validada e integrada con metadatos completos.
2. Mapa celular anotado con identificación de compartimento epitelial tumoral.
3. Evaluación preliminar del papel del microambiente en la progresión.
4. Lista robusta de genes diferencialmente expresados asociados a metástasis.
5. Modelo discriminativo validado e identificación de genes clave.
6. Métrica cuantitativa de activación del programa metastásico.
7. Identificación de procesos biológicos asociados a la firma metastásica.
8. Evaluación contextual de la firma metastásica.
9. Documento completo listo para entrega.

7.4 Análisis de riesgos

Los riesgos analizados se encuentran en la tabla 2.

8 Resultados esperados

Al finalizar el proyecto se espera obtener:

- Una matriz con datos scRNAseq curada y documentada.
- Caracterización de la arquitectura celular tumoral.
- Lista de genes diferencialmente expresados.
- Conjunto de genes candidatos asociados a diferencias transcriptómicas entre tumor primario y metástasis ganglionar.
- Resultados de enriquecimiento funcional.
- Modelo supervisado entrenado y validado.
- Definición y cálculo de un puntaje metastásico cuantitativo.
- Un pipeline reproducible para el análisis de single-cell RNAseq.
- Código documentado y estructurado para reproducibilidad.

9 Bibliografia

- [1] Sung, H., Ferlay, J., Siegel, R. L., Laversanne, M., Soerjomataram, I., Jemal, A., & Bray, F. (2021). Global Cancer Statistics 2020: GLOBOCAN Estimates of Incidence and Mortality Worldwide for 36 Cancers in 185 Countries. *CA: a cancer journal for clinicians*, 71(3), 209–249. <https://doi.org/10.3322/caac.21660>
- [2] Dagogo-Jack, I., & Shaw, A. T. (2018). Tumour heterogeneity and resistance to cancer therapies. *Nature reviews. Clinical oncology*, 15(2), 81–94. <https://doi.org/10.1038/nrclinonc.2017.166>
- [3] Tang, F., Barbacioru, C., Wang, Y. et al. mRNA-Seq whole-transcriptome analysis of a single cell. *Nat Methods* 6, 377–382 (2009). <https://doi.org/10.1038/nmeth.1315>
- [4] Kolodziejczyk, A. A., Kim, J. K., Svensson, V., Marioni, J. C., & Teichmann, S. A. (2015). The technology and biology of single-cell RNA sequencing. *Molecular Cell*, 58(4), 610–620. <https://doi.org/10.1016/j.molcel.2015.04.005>.
- [5] Bian, S., Hou, Y., Zhou, X., Li, X., Yong, J., Wang, Y., Wang, W., Yan, J., Hu, B., Guo, H., Wang, J., Gao, S., Mao, Y., Dong, J., Zhu, P., Xiu, D., Yan, L., Wen, L., Qiao, J., Tang, F., ... Fu, W. (2018). Single-cell multiomics sequencing and analyses of human colorectal cancer. *Science (New York, N.Y.)*, 362(6418), 1060–1063. <https://doi.org/10.1126/science.aao3791>
- [6] Luecken, M. D., & Theis, F. J. (2019). Current best practices in single-cell RNA-seq analysis: a tutorial. *Molecular systems biology*, 15(6), e8746. <https://doi.org/10.15252/msb.20188746>

Tabla 2: Tabla de análisis de riesgos

Riesgo	Descripción	Impacto potencial	Probabilidad	Estrategia de mitigación
Alcance excesivo del proyecto	Intentar abordar simultáneamente heterogeneidad celular, firma metastásica, validación clínica fuerte y comparación con normal.	Dispersión de resultados y pérdida de foco	Media	Priorizar los objetivos específicos centrales (firma metastásica PT vs LN) y relegar los análisis exploratorios si el tiempo es limitado.
Limitación temporal	El análisis single-cell y ML requiere iteraciones, validación y optimización	Resultados incompletos o poco refinados.	Media	Definir desde el inicio un flujo de análisis cerrado y evitar cambios metodológicos tardíos.
Señal biológica insuficiente	Las diferencias transcriptómicas podrían ser débiles, altamente variables o no reproducibles entre pacientes.	Imposibilidad de definir una firma consistente o modelo predictivo robusto	Media	Ajustar alcance del objetivo.
Bajo número de pacientes (N=6)	La unidad biológica independiente es limitada	Sobreinterpretación estadística o baja potencia.	Alta	Uso de pseudobulk por paciente, validación leave-one-out y formulación prudente de conclusiones.
Bajo número de células normales	Solo 19 células normales disponibles.	Comparaciones Normal vs Tumor estadísticamente débiles	Alta	Plantear análisis con tejido normal como exploratorio y no central.
Dependencia entre células (pseudorreplicación)	Tratamiento incorrecto de células como observaciones independientes	Inflación artificial de significación.	Alta	Agregación pseudobulk y análisis a nivel paciente.
Heterogeneidad interpaciente elevada	Variabilidad biológica real entre pacientes	Dificultad para identificar firma consistente.	Media	Modelos que controlen efecto paciente y evaluación de estabilidad de genes seleccionados.
Sobreajuste en modelos de ML	Dataset de tamaño reducido para clasificación supervisada	Modelos con buen rendimiento aparente pero baja generalización.	Media	Validación cruzada estricta y limitación de complejidad del modelo.
Problemas en anotación celular	Errores en identificación de tipos celulares.	Interpretación biológica incorrecta	Media	Uso combinado de métodos automáticos (SingleR) y marcadores conocidos.
Resultados biológicamente poco interpretables	Firma sin enriquecimiento funcional claro.	Dificultad en discusión científica	Baja-media	Análisis de enriquecimiento en múltiples bases y contextualización en literatura.
Problemas técnicos en integración de archivos TPM	Errores en construcción de matriz de expresión.	Retrasos iniciales	Baja	Validación paso a paso y control de consistencia de datos.